Name	Matthias Janßen
Matr.Nr.	1871808
Inhaltsskizze zu Block	Agents in SE

Titel des Papiers:

Not All Problems Are Nails, Not All Tools Should Be Hammers: A Position Paper on Agent Usage in Software Engineering Tasks

Kurzzusammenfassung:

- **Grund:**
  - LLM-Agenten für immer mehr SE-Aufgaben, Trend: Agenten für jedes Problem
  - Citizen Developer bauen Software ohne technischen Hintergrund
  - KI keine Universallösung: nur 5% der Custom-Tools und 40% der General-Purpose-LLMs erreichen die Produktion
  - Frage: wie, von wem und wann sollen SE-Aufgaben automatisiert werden?
- **Strategie:**
  - Position Paper: kein eigenes Experiment, argumentiert aus bestehender Forschung
  - Schritte: LLM-Grenzen → Folgen für Code + Industrie → Hintergrund der Nutzer → Use-Case-Tabelle → geeignete Probleme
- **Ergebnisse:**
  - Grenzen: Halluzinationen, Scheinkorrelationen, Schmeichelei, lange Kontexte
  - Benchmarks ausnutzbar, neue Bedrohungen (Prompt Injection, Sleeper Agents)
  - Code: lokale Lösungen, mehr Churn, weniger Reuse, Sicherheitslücken
  - Produktivität gemischt: erfahrene OSS-Entwickler 19% langsamer (n=16), andere Studie: höhere Arbeitszufriedenheit
  - nur nützlich, wenn Nutzer den Output prüfen kann → Hintergrund entscheidet:
    - stark: meiste Freiheit, validiert Output, Einsatz für Routineaufgaben + QS
    - mittel: Output darf ins Produkt, Einzelfallprüfung, Whitelist für Pakete
    - nicht-technisch: sieht Black Box → Prototypen + Problemskizze, kein Produktiveinsatz ohne Prüfung durch Fachkraft
  - Use-Case-Tabelle: Prototypen für alle, QS + Recherche nicht für Nicht-Techniker
  - gute Probleme: klare Definition, prüfbarer Output, fehlertolerant
  - 90% der Lebenszykluskosten sind Wartung → diese automatisieren, nicht nur Neubau
  - künftige Forschung: Grenzen von Nutzern und Tools, nicht nur Fähigkeiten

Name	Matthias Janßen
Matr.Nr.	1871808
Inhaltsskizze zu Block	Agents in SE

Eigene (offene) Diskussionspunkte:

- **Urteil:** wissenschaftlich als Position Paper, aber nicht empirisch → Aussagen sind gut begründete Hypothesen, keine belegten Ergebnisse
- **Wissenschaftlich:**
  - offen als Position gekennzeichnet („we argue“), auf ACM-Workshop veröffentlicht
  - 78 Referenzen, meiste Aussagen nachvollziehbar, klare Argumentationslinie
- **Nicht wissenschaftlich:**
  - keine formalen Forschungsfragen, keine Methode, keine Threats to Validity
  - Literaturauswahl nicht offengelegt → Gefahr von Cherry-Picking
  - Use-Case-Tabelle: Bewertung ohne Kriterien + Validierung → Meinung der Autoren
  - viele Quellen ohne Peer Review: ca. 20 arXiv-Preprints, Reports von GitClear + Chroma, MIT-Report nur als Link
  - dünne oder übertragene Belege: kleine Stichproben (n=16), vorläufige Studie zum Essay-Schreiben auf SE übertragen, Wartungskosten von 2005/2013 (vor LLMs)
  - unbelegte Aussagen: Citizen Developer erhöhen Denial-of-Wallet-Risiko deutlich, Mustertreue macht KI „ideal“ für QS
- **Offene Fragen:**
  - Zeitrahmen? Wie lange gelten die Grenzen bei so schnellen Modellsprüngen?
  - Wer prüft Citizen-Developer-Output in der Praxis? Frisst das die Zeitersparnis auf?
  - Wo liegt die Grenze zwischen den drei Nutzergruppen? Wer zählt als mittel?
  - Lässt sich die Use-Case-Tabelle empirisch prüfen?