Report

> **Hinweis:** Die Erklärungen und Bewertungen von Code wurden persönlich gelesen und anschließend von KI zusammengetragen.

Aufgabe 0: Wahl der Bots

- Claude:
  - state of the art
  - für viele der Standard von Code Generierung
- Gemini:
  - verbreitet bei nicht technischen Nutzern
- Deepseek
  - Chinesisches Unternehmen
  - Vergleich USA vs China
- Jetbrains
  - Integriert in IDE
  - Convenience

Modelle

- Claude: Opus 5.5, hoher Denkaufwand
- Gemini: Pro bei Generierung, Flash bei Erklärung (wegen zu hoher Auslastung)
- Deepseek: intelligente Suche und tiefes Denken
- Jetbrains: openai-gpt-5-5

Aufgabe 1: Kodeerzeugung

Prompt-Template und Chats: siehe separate TXT-Dateien.

Programmieraufgabe

- Schach in der Vorlesung vorgestellt, daher Idee eines Brettspiels
- Ergebnis: Stratego
- Gründe für Stratego
  - verschiedene Bewegungsmuster
  - Sonderregeln
  - limitierter Umfang (Tokenlimits)

Findings

Claude

- Detaillierte Erklärung der Dateistruktur
- teilweise Erklärung der Regeln
- Error Handling falls tkinter failed

- auch ohne gui verwendbar
- Datei durch Kommentare unterteilt
- Erklärung aller Klassen und Methoden
- Ausgearbeitete GUI, optisch ansprechend
- Zug Historie
- Übersicht verbleibender Figuren
- Anzeigen möglicher Züge nach Figurauswahl
- Erklärung von illegalen Zügen
- Spielbrett rotiert
- Keine Rückfrage bezüglich Positionierung von Fahnen und Bomben (rein zufällig)
- Gibt Empfehlungen bei Rückfragen
- Keine Möglichkeit Spiel frühzeitig zu beenden (außer Anwendung schließen)
- Kurze Erklärung des Spiels bei Anfrage
- Tests

Gemini

- Wenige Kommentare
- Weniger offensichtlich strukturiert
- Minimalistisches GUI
- Kein Anzeigen Möglicher Züge
- Kein Hinweis bei illegalen Zügen
- Keine Angabe über Zug des gegnerischen Spielers
- Spielbrett starr
- Keine Rückfragen vor Generierung, erst als weitere Schritte
- Kurze Übersicht der Regeln

Deepseek

- Kommentar zur Erklärung der Datei
- Verweis auf Regeldatei (Besonderheit Regeln nicht als PDF übergeben sondern als Link
- Datei durch Kommentare strukturiert
- Methoden Kommentiert
- Sonderregeln für Aufklärer Kommentiert
- Erklären von Methoden / if-else Zweigen
- GUI minimalistisch (Quadrate)
- Hervorheben von möglichen Feldern nach Figuren Auswahl
- Kein Erklären von Illegalen Zügen
- Zugübersicht auf Zwischenbildschirm
- Figuren "verlieren" nach Zug ihre Farbe
- Spielbrett starr
- Keine Fragen vor erster Version, als offene Punkte nachgefragt

Jetbrains (openai-gpt-5-5)

- Erste Version nicht ausführbar
- Keine Kommentare
- Code generiert trotz nachfragen
- Minimalistische GUI
- Legale Züge hervorgehoben
- Kein Hinweis über letzten Zug des Gegners
- Zwischenfenster als seperates Fenster, lässt sich verschieben
- Spielbrett starr

Vergleich

- Claude
  - am weitesten bezüglich UI
  - klarste Struktur der Datei
  - testet als einziges die Anwendung
  - Code nur als Datei
  - stellt Rückfragen vor Generierung und gibt Empfehlungen
- Gemini
  - UI okay
  - weniger gut strukturiert als Claude
  - gibt Regelübersicht
  - keine Rückfragen vor Generierung
- Deepseek
  - schnellste Antwort
  - Code vollständig in der Antwort
  - schwächste UI
  - gute Kommentare
  - Nachfragen erst nach Erstellen einer ersten Version
- Jetbrains
  - als einziges mit Fehler (erste Version nicht ausführbar)
  - schwache Entscheidungen bezüglich verschiebbarem Zwischenfenster
  - Code vollständig in der Antwort
  - schwächere UI
  - stellt Rückfragen, generiert aber eine Version bevor diese beantwortet wurden

Aufgabe 2: Kodebewertung/-analyse

Prompt-Template und Chats: siehe separate TXT-Dateien.

Judge Claude

Claude

Gesamt 7.75/10

- sauber strukturiert und gut lesbar

- Abzüge für große UI-Klasse, kleine Überbleibsel und mehrfach hinterlegtes Wissen

Code Smells 7/10

- positiv:
  - Logik und UI getrennt
  - Enums
  - custom exception
- negativ
  - God Class
  - Extrem Lange Regelprüfung (12 return werte)
  - toter Code
  - weggeworfenes Objekt
  - Doppeltes Rendering
  - Magic Numbers

Duplikate 7.5/10

- Seen-Geometrie
- hin-und-her Regel
- UI Texte
- Kleinere Duplikate
  - cover_text
  - draw_selection
  - set_hint
  - Splaten
  - canvas.delete

Lesbarkeit 8.5/10

- positiv
  - sprechende Namen
  - kurze Methoden
  - Annotationen schlüssig
- negativ
  - Datei Länge
    - Aufteilen in game und ui sinnvoll
  - Überlange Zeilen
  - viele Parameter
  - alte Syntax

Kommentare 8/10

- positiv
  - modul docstring
  - Kommentare erklären warum
  - kein auskommentierter Code / TODOs
- negativ
  - Fehlende Erklärungen
  - Fehlende Docstrings
  - Unpräzise Kommentare

- Unerklärte Konstanten

Logikfehler

- Keine genannt
- Geprüft mit pyflakes, pylint, radon und vulture
- 300 simulierte Zufallspartien endeten regulär und ohne Absturz
- Oberfläche nur gelesen, nicht ausgeführt

Gemini

Gesamt 6/10

- für Prototyp gut lesbar und übersichtlich
- Spiellogik und UI stark vermischt
- dadurch schwer testbar und erweiterbar

Code Smells 5/10

- negativ
  - God Class
  - Zu lange Methode (execute_move)
  - Magic Strings
  - Uneinheitlicher Rangtyp
  - Magic Numbers
  - Namenskollision (self.state)
  - Flag-Variablen (win, draw)
  - Kleinere Punkte
    - verschachtelte Funktion (get_random_pieces)
    - self.lakes besser als set

Duplikate 6/10

- Figuren zeichnen
- Koordinaten
- Auswahlprüfung
- Aufstellung
- Gegner bestimmen
- Figur bewegen
- Spielende

Lesbarkeit 7/10

- positiv
  - klare Methodennamen
  - logischer Aufbau
  - moderate Verschachtelung
  - knappe Variablennamen im Kontext verständlich
- negativ
  - Kampflogik schwer zu überblicken
  - Einzeiler gegen PEP 8
  - Sprachen gemischt (englische Bezeichner, deutsche Werte)
  - Fehlende Type Hints

Kommentare 6/10

- positiv
  - Legende der Ränge am Dateianfang
  - Kommentare erklären Fachregeln
- negativ
  - Fehlende Docstrings
  - Redundante Kommentare
  - Versteckte Lücke in has_movable_pieces
  - Liegen gebliebene Notiz

Logikfehler

- Spiel kann hängen bleiben (kein Spielende bei blockiertem Spieler)
- Falscher Sieger möglich
- Verteidiger erfährt nichts vom Kampf

Deepseek

Gesamt 6/10

- solide Struktur
- Spiellogik weitgehend von GUI getrennt
- Abzüge für String-basierte Logik, zu lange Methoden und drei Fehler

Code Smells 5/10

- positiv:
  - Logik und GUI weitgehend getrennt
- negativ
  - Stringly-typed Logik
  - Untypisiertes Ergebnis (_resolve_attack)
  - Unnötige Zustandsänderung (_has_movable_pieces)
  - Vermischte Verantwortlichkeiten
  - Lange Methoden (_on_cell_click, move, _refresh_board)
  - Toter Code
  - Magic Values
  - Stilles Abschneiden (zip)
  - Schwer testbar

Duplikate 7/10

- Bewegungslogik
- Zugausführung
- Gegnerermittlung
- GUI-Zustand
- Validierung
- Statustexte

Lesbarkeit 7/10

- positiv
  - klare Gliederung der Datei
  - aussagekräftige Namen

    - verständliches Datenmodell (Dataclasses, PIECE_DEFS)
- negativ
    - Knappe Koordinaten (fr, fc, tr, tc)
    - Irreführender Name (_has_movable_pieces)
    - Verschachtelte Ternary-Kette
    - Lückenhafte Type Hints

Kommentare 6/10

- positiv
    - Dateikopf (Zweck, Regelquelle, Startbefehl)
    - Kommentare erklären warum
- negativ
    - Fehlende Docstrings
    - Irreführender Kommentar
    - Uneinheitliche Begriffe
    - Redundante Kommentare

Logikfehler

- Zwei-Felder-Regel greift nie
- Gegner erfährt verdeckte Figuren
- Figuren des nächsten Spielers werden sichtbar
- grab_set() kann unter Linux/X11 abbrechen

Jetbrains

Gesamt ca. 6/10

- solide Struktur
- Logik und UI getrennt
- Methoden überwiegend klein
- Typannotationen konsequent
- Schwächen bei Kommentaren, totem Code und Rängen / Spielern als Strings

Code Smells 6/10

- positiv:
    - Logik und UI getrennt
- negativ
    - Toter Code (_create_piece_set)
    - Wirkungslose Logik (_strategic_bomb_positions)
    - Unnötiges Mischen
    - Primitive Obsession
    - Temporäre Zustandsänderung (has_any_legal_move)
    - Vermischte Verantwortung
    - Zu lange Methoden (_place_strategic_army, _on_cell_clicked, _refresh_board)
    - Magic Values
    - Umständliche Verzweigung

Duplikate 6/10

- Doppelte Zugregeln
- Doppelte Vorprüfungen
- Kleinere Duplikate
  - Bewegungsrichtungen
  - Spielerwechsel
  - Figur bewegen
  - free_positions
  - Auswahl zurücksetzen
  - Board-Initialisierung
  - Figurennamen

Lesbarkeit 8/10

- positiv
  - sprechende Namen
  - einheitliche Formatierung und Typannotationen
  - Early Returns halten Verschachtelung niedrig
- negativ
  - _refresh_board nicht kompakt
  - _is_clear_straight_line unnötig lang
  - Ränge nur mit Blick in Tabelle verständlich
  - Fehlender Typalias (Position)

Kommentare 3/10

- negativ
  - Keine Docstrings
  - Einzige Kommentare wiederholen PIECE_NAMES
  - Fehlende Erklärungen
    - Sonderregeln
    - Strategie der Aufstellung
    - Verhalten bei fehlenden Zugmöglichkeiten

Logikfehler

- Geheime Figuren werden aufgedeckt
- Kampfergebnisse fehlen beim Gegner

Vergleich

KI	Code Smells	Duplikate	Lesbarkeit	Kommentare	Schnitt (berechnet)	Gesamt (Review)
Claude	7	7.5	8.5	8	7.75	7.75
Gemini	5	6	7	6	6	6
Deepseek	5	7	7	6	6.25	6
Jetbrains	6	6	8	3	5.75	ca. 6

Auffälligkeiten

- Claude in allen vier Kategorien vorne
  - Judge ist selbst Claude, Bias möglich
  - Gegenprobe mit anderem Judge sinnvoll
- Gesamtnoten fast identisch
  - Gemini, Deepseek und Jetbrains jeweils um 6/10
  - Stärken und Schwächen unterscheiden sich trotzdem deutlich
  - Claude mit 7.75/10 klar darüber
- Größte Spanne bei Kommentaren (3 bis 8)
  - Jetbrains: Lesbarkeit 8/10 trotz Kommentare 3/10, gute Benennung fängt einiges auf
  - Deepseek gleich bewertet wie Gemini (6/10), obwohl laut Findings deutlich mehr kommentiert
- Modellierung
  - nur Claude nutzt Enums
  - Gemini, Deepseek und Jetbrains arbeiten mit Strings
- Trennung von Logik und UI
  - bei Claude, Deepseek und Jetbrains vorhanden
  - bei Gemini stark vermischt
  - Claude trotz Trennung mit God Class
- Gemeinsame Schwächen in allen vier Reviews
  - Magic Numbers / Magic Values
  - Lange Methoden
  - Fehlende Docstrings
- Gleiche Duplikate bei Gemini, Deepseek und Jetbrains
  - Gegner bestimmen
  - Figur bewegen
- Ähnliche Logikfehler
  - Gemini und Jetbrains: Verteidiger erfährt nichts vom Kampf
  - Deepseek und Jetbrains: geheime Figuren werden sichtbar
  - Claude: keine genannt
- Einschränkungen der Bewertung
  - Logikfehler uneinheitlich gewertet: bei Deepseek Abzug in der Gesamtnote, bei Gemini und Jetbrains außerhalb der Wertung
  - Prüfung uneinheitlich: nur das Claude-Review nennt Tools und 300 simulierte Partien
  - Claude-Oberfläche nicht ausgeführt, Fehler im GUI-Ablauf dadurch nicht ausgeschlossen
  - Gesamtnote bei Claude als genauer Schnitt, bei Deepseek und Jetbrains gerundet
  - Deepseek-Review: Code nur gelesen, nicht ausgeführt, Fehler also nicht durch Ausführen bestätigt
  - Nur Claude mit halben Punkten bewertet

Aufgabe 3: Kodeerklärung

Prompt-Template und Chats: siehe separate TXT-Dateien.

Claude

- Kurze Einordnung vorab
  - Zweck der Methode (_draw_token zeichnet einzelnen Spielstein auf Tkinter-Canvas)
  - Stratego-artiges Spiel aus dem Code erkannt (Bombe, Fahne, Spion, Stärkewerte)
- Erklärung aller Parameter
  - Forward Reference bei "tk.Canvas" erklärt
  - rank = None bedeutet verdeckter Stein
- Schritt für Schritt in 6 Abschnitten mit Codeausschnitten
  - Stil und Maße bestimmen
  - Stein mit 3D-Effekt zeichnen
  - Mittelpunkt berechnen
  - Verdeckten Stein zeichnen
  - Symbol oder Zahl zeichnen
  - Kurznamen darunter schreiben
- Erklärt auch das Warum
  - Maße hängen von size ab, Stein skaliert mit
  - Zeichenreihenfolge erzeugt den 3D-Effekt
  - Mindest-Linienstärke durch max(2, ...)
- Erklärt allgemeine Konzepte
  - Guard Clause / Early Return
  - Enum-Vergleich mit is
- Tabelle zur Darstellung je Rang
- Rechenbeispiel für size = 100
- ASCII-Skizze des Steins
- Annahmen gekennzeichnet
  - "vermutlich" bei x, y und dem True in _font
  - rounded_rect, draw_sabres, COLOR_STYLES und _font nicht sichtbar, aus Namen und Verwendung abgeleitet
- Kleine Ungenauigkeit: Text nennt drei Fälle, Tabelle zeigt vier Zeilen

Gemini

- Kurze Einordnung vorab
  - Zweck der Methode (_draw_token rendert einzelnen Spielstein auf Tkinter-Canvas)
  - Stratego als Beispiel genannt
- Erklärung aller Parameter
  - rank = None bedeutet verdeckter Stein
  - Forward Reference nicht erklärt
- Gliederung nach Themen statt nach Codeablauf
  - Parameter und Funktionskopf
  - Geometrie und 3D-Optik
  - Verdeckt vs. aufgedeckt
- Keine Codeausschnitte, nur einzelne Ausdrücke im Text

- Kein Rechenbeispiel
- Keine Skizze oder Tabelle
- Abschließende Key Takeaways zu Clean Code
  - Vollständige Skalierbarkeit
  - Separation of Concerns
  - Guard Clauses
- Annahmen nicht gekennzeichnet
  - gekreuzte Säbel, dunklere Kantenfarbe und fette Schrift als Tatsache beschrieben
  - Beispielwerte für rank.short ("B", "F", "Sp") nicht aus dem Code ableitbar
- Ungenauigkeiten
  - Oberseite laut Antwort nach oben versetzt, tatsächlich nur unterer Rand um size * 0.01 gekürzt
  - "vollständig relative Maße", aber Mindest-Linienstärke max(2, ...) ist fester Wert und wird nicht erwähnt
  - Tippfehler ("Dictionairy", "Zielsfeldes")

Deepseek

- Kurze Einordnung vorab
  - Zweck der Methode (_draw_token zeichnet einzelnen Spielstein auf tk.Canvas)
  - Stratego-ähnliches Brettspiel genannt
- Erklärung aller Parameter als Tabelle
  - inklusive Rückgabewert
  - rank = None bedeutet unbekannte Figur
  - Forward Reference nicht erklärt
- Gliederung in 9 Abschnitte, Code Schritt für Schritt mit Ausschnitten
  - Signatur und Parameter
  - Farb-Styling nachschlagen
  - Geometrie
  - 3D-Effekt durch zwei Schichten
  - Zentrum berechnen
  - Fall 1: unbekannte Figur
  - Fall 2: bekannter Rang
  - Didaktische Takeaways
  - Kleine Schwachstellen
- Erklärt auch das Warum
  - Maße relativ zu size, Stein bleibt bei jeder Größe gleich
  - 3D-Effekt als 2D-Trick ("fake extrusion")
  - Mindest-Linienstärke durch max(2, ...)
  - Oberseite unten gekürzt, damit Kante sichtbar bleibt
- Erklärt allgemeine Konzepte
  - Early Return
  - Enum-Vergleich mit is
  - Delegation
  - Single Source of Truth

- 7 didaktische Takeaways
- Kein Rechenbeispiel
- Keine Skizze
- Kritische Einordnung des Codes (Schwachstellen / Diskussionspunkte)
  - Unbenannte Magic Numbers
  - x, y als Ecke nicht offensichtlich, Docstring fehlt
  - String-Keys in style statt TypedDict oder dataclass
- Annahmen nur teilweise gekennzeichnet
  - "vermutlich" bei den Keys von COLOR_STYLES und dem True in _font
  - gekreuzte Säbel und Parameter von draw_sabres als Tatsache beschrieben
- Ungenauigkeiten
  - Takeaway "Guard-Clauses für Schriftgrößen", max(2, size * 0.04) ist aber Linienstärke und keine Guard Clause
  - x, y und size als Maße des Tokens bezeichnet, tatsächlich des Felds (Stein um inset kleiner)
  - "Farben kommen aus COLOR_STYLES", Textfarbe kommt aber aus TEXT

Jetbrains

- Hinweis: Agent greift auf Dateien im Ordner zu, Resultat daher verzerrt
  - Antwort kennt Details außerhalb der Methode (z. B. Key "hover" in COLOR_STYLES)
  - Nicht direkt mit den anderen drei Antworten vergleichbar
- Kurze Einordnung vorab
  - Zweck der Methode (_draw_token zeichnet einzelnen Stratego-Spielstein auf tkinter.Canvas)
  - Rolle im Programm: nur Darstellung, keine Spiellogik
- Erklärung aller Parameter als Tabelle
  - rank = None bedeutet verdeckte Figur
  - Forward Reference nicht erklärt
- Sehr ausführlich, kleinteilig Schritt für Schritt in 10 Abschnitten mit Codeausschnitten
  - Farbstil auswählen
  - Innenabstand und Koordinaten berechnen
  - Stein mit Schatten / Kante zeichnen
  - Mittelpunkt berechnen
  - Verdeckte Figur
  - Position für Rangsymbol
  - Bombe
  - Fahne
  - Zahl oder S für Spion
  - Kurzname
- Einzelne Zeilen und Argumente werden teils mehrfach wiederholt
- Zusätzliche Abschnitte
  - Gesamtbild als Pseudocode
  - Warum rank: Optional[Rank] wichtig ist (statt visible: bool)
  - Durchlauf für sichtbare und verdeckte Figur
  - Übersicht der verwendeten Methoden

    - Kurzes Fazit
- Mehrere Tabellen (Parameter, Style-Keys, Variablen, Anzeige je Rang, rank.short)
- Kleines Rechenbeispiel (inset für size = 60)
- ASCII-Skizze des Steins
- Allgemeine Konzepte kaum benannt
    - Early Return nicht als Muster benannt
    - Enum-Vergleich mit is nicht erklärt
    - Keine Kritik am Code
- Annahmen nur bei rank.short gekennzeichnet ("vermutlich")
    - Durch Dateizugriff nicht beurteilbar, was abgeleitet und was gelesen ist
- Ungenauigkeit: rounded_rect, draw_sabres, _draw_bomb und _draw_flag als "tkinter-Methoden" gelistet, sind aber eigene Hilfsfunktionen

Vergleich

Merkmal	Claude	Gemini	Deepseek	Jetbrains
Wörter	705	411	1038	1419
Codeblöcke	7	0	9	34
Tabellen	2	0	1	6
Rechenbeispiel	ja (size = 100)	nein	nein	klein (size = 60)
Skizze	ja	nein	nein	ja
Forward Reference erklärt	ja	nein	nein	nein
max(2, ...) erklärt	ja	nein	ja	ja
Early Return benannt	ja	ja	ja	nein
Enum-Vergleich mit is erklärt	ja	nein	ja	nein
Annahmen gekennzeichnet	ja	nein	teilweise	nur rank.short
Kritik am Code	nein	nein	ja	nein

Auffälligkeiten

- Kernaussage bei allen gleich
    - Methode zeichnet einzelnen Spielstein
    - 3D-Effekt durch zwei übereinanderliegende Rechtecke
    - rank = None führt zur verdeckten Darstellung
    - Stratego von allen erkannt, obwohl der Name im Code nicht vorkommt
- Umfang stark unterschiedlich
    - Jetbrains rund 3.5-mal so lang wie Gemini
    - Mehr Text bedeutet nicht mehr Inhalt, Jetbrains wiederholt Zeilen und Argumente mehrfach
- Unterschiedliche Zielgruppen
    - Gemini: kompakter Überblick für Erfahrene
    - Claude: Mittelweg aus Erklärung und Konzepten
    - Deepseek: didaktisch, mit Takeaways und Kritik

    - Jetbrains: Einsteiger, erklärt jedes Argument einzeln
- Aufbau
    - Claude, Deepseek und Jetbrains folgen dem Code Schritt für Schritt
    - Gemini gliedert nach Themen und verzichtet auf Codeblöcke
- Alleinstellungsmerkmale
    - Claude: Forward Reference, vollständiges Rechenbeispiel, Grenzen der Antwort offen benannt
    - Gemini: Einordnung in Clean-Code-Prinzipien
    - Deepseek: benennt Schwachstellen des Codes
    - Jetbrains: Pseudocode-Überblick, Durchlauf für sichtbare und verdeckte Figur
- Umgang mit Unsicherheit
    - Nicht sichtbare Hilfsfunktionen nur bei Claude klar als abgeleitet gekennzeichnet
    - Gemini beschreibt Annahmen durchgehend als Tatsachen
- Erfundene Beispielwerte widersprechen sich
    - Major hat bei Claude 8, bei Deepseek 7
    - rank.short: "Major" (Claude), "Sp" (Gemini), "MAJ" (Deepseek), "Hauptm." (Jetbrains)
    - Aus dem Code allein nicht ableitbar
- Fehler sind eher Details
    - Claude: Text und Tabelle uneinheitlich
    - Gemini: 3D-Effekt ungenau, Mindest-Linienstärke fehlt
    - Deepseek: falscher Begriff Guard Clause, Feld und Stein vermischt
    - Jetbrains: eigene Hilfsfunktionen als tkinter-Methoden gelistet
- Einschränkungen
    - Jetbrains hatte Zugriff auf Dateien im Ordner, Ergebnis nicht direkt vergleichbar
    - Gemini nur mit Flash statt Pro, kürzeste Antwort daher nicht allein dem Chatbot zuzuschreiben