

Übersetzung und Analyse von Programmen

The background is a stylized, low-poly illustration. It features a large, multi-story building with a grid of windows in shades of blue and green. In the foreground, there are two green trees with yellow leaves, a large white flower with a yellow center, and a bright yellow sun in the upper right corner. The overall color palette is dominated by blues, greens, and yellows.

Vorlesung im Wintersemester 2025/26


Prof. Dr. Stephan Diehl

Informatik, Universität Trier




- Lexikalische Analyse
 - Zerlegung des Quelltexts in logische Einheiten
 - Reguläre Ausdrücke, endliche Automaten
 - Generierung eines Scanners

Struktur eines Compilers



Struktur eines Compilers

Scanner




Quelle: Übersetzerbau, Wilhelm & Maurer, 1992

(A) Lexikalische Analyse
(B) Filtern/Sieben
(C) Syntaktische Analyse

Lexem

Muster

Zusammenspiel zwischen Scanner und Parser



Symboltabelle

- Speicherung von Informationen über die im Programm verwendeten Bezeichner
 - String/Lexem, Typ, Speicherort, ...
- Informationen werden während der Analysephase (Frontend) schrittweise ergänzt
- Je eine Tabelle pro Gültigkeitsbereich

Beispiel:

a	int	
b	int	

Worte und Sprachen

Worte und Sprachen

- Ein **Alphabet** Σ ist eine endliche, nichtleere Menge von Zeichen.
- Ein **Wort** x über Σ der Länge n ist eine endliche Folge von Zeichen aus Σ :
 $x : \{1, \dots, n\} \rightarrow \Sigma$ in Zeichen: $x_1 x_2 \dots x_n$
- Das **leere Wort** ε ist das Wort, das aus keinem Zeichen besteht: $\varepsilon : \emptyset \rightarrow \Sigma$
- Menge des leeren Wortes: $\Sigma^0 = \{\varepsilon\}$
- Menge der Worte der Länge n : $\Sigma^n = \{x \mid x : \{1, \dots, n\} \rightarrow \Sigma\}$
- Menge aller Worte über Σ : $\Sigma^* = \bigcup_{i=0}^{\infty} \Sigma^i$
- Menge aller nichtleeren Worte über Σ : $\Sigma^+ = \bigcup_{i=1}^{\infty} \Sigma^i$

Worte und Sprachen

- $x.y$ ist die **Konkatenation** von x und y .
 $x.y = x_1 \dots x_n y_1 \dots y_m$ mit $x = x_1 \dots x_n$ und $y = y_1 \dots y_m$
- **Bemerkungen**
 - Das leere Wort ist **neutrales Element** bezüglich der Konkatenation von Worten: $x.\varepsilon = \varepsilon.x = x$ für alle $x \in \Sigma^*$
 - Die Konkatenation ist **assoziativ**: $x.(y.z) = (x.y).z$
 - Wir schreiben im folgenden xy für $x.y$

Weitere Begriffe

Sei $w = xyz$ mit $x, y, z \in \Sigma^*$. Dann ist

- x ein **Präfix** von w
 - Falls $yz \neq \varepsilon \neq x$ gilt, ist x ein **echter Präfix** von w
- z ein **Suffix** von w
 - Falls $xy \neq \varepsilon \neq z$ gilt, ist z ein **echter Suffix** von w
- y ein **Teilwort** von w
 - Falls $xz \neq \varepsilon \neq y$ gilt, ist y ein **echtes Teilwort** von w

Operationen auf formalen Sprachen

Formale **Sprachen** über Σ sind Teilmengen von Σ^* .

Seien $L, L_1, L_2 \dots$ formale Sprachen

- Vereinigung von Sprachen: $L_1 \cup L_2 = \{w \mid w \in L_1 \text{ oder } w \in L_2\}$
- Konkatenation von Sprachen: $L_1 L_2 = \{xy \mid x \in L_1, y \in L_2\}$
- Komplement einer Sprache: $\neg L = \Sigma^* - L$
- Potenz einer Sprache: $L^0 = \{\varepsilon\}, L^{n+1} = L^n L$
- Abschluss (Hülle) einer Sprache: $L^* = \bigcup_{i=0}^{\infty} L^i$
- Positiver Abschluss (Hülle) einer Sprache: $L^+ = \bigcup_{i=1}^{\infty} L^i$


Definition: Reguläre Sprache

- Die **regulären Sprachen** über Σ werden induktiv definiert durch:
 - $\emptyset, \{\varepsilon\}$ sind reguläre Sprachen über Σ .
 - Für alle $a \in \Sigma$ ist $\{a\}$ eine reguläre Sprache.
 - Sind R_1 und R_2 reguläre Sprachen über Σ , so auch
 - $R_1 \cup R_2$,
 - $R_1 R_2$,
 - und R_1^* bzw. R_2^*
 - Nichts sonst ist eine reguläre Sprache über Σ .

Lexikalische Analyse

- **Reguläre Sprachen** können durch **reguläre Ausdrücke** beschrieben werden.
- Deshalb bilden diese die Basis für alle Sprachen zur Spezifikation der **lexikalischen Analyse**.
- Reguläre Sprachen können durch **endliche Automaten** erkannt werden.

Lexikalische Analyse



Reguläre Ausdrücke

- Betrachte als Beispiel Bezeichner, wie etwa **begin**, **end**, **xyz123**, **y2**
- Natürlichsprachliche Spezifikation:
 - *Bezeichner bestehen aus einer Aneinanderreihung von Buchstaben und Ziffern, wobei das erste Zeichen ein Buchstabe sein muss.*
- Kürzer: ein **BUCHSTABE**, dann beliebig oft (ein **BUCHSTABE** oder eine **ZIFFER**)
 - **DANN** entspricht der Konkatination zweier Worte,
 - **ODER** entspricht der Alternative zwischen zwei Worten (in Zeichen: |),
 - **BELIEBIG OFT** entspricht dem Kleene-Stern (in Zeichen: *).
- Als regulärer Ausdruck: **bu (bu | zi)***
 - Dies ist ein regulärer Ausdruck wobei **bu** und **zi** auch wieder reguläre Ausdrücke sind
 - bu** = a | b | c ... | y | z
 - zi** = 0 | 1 | ... | 9

Definition: regulärer Ausdruck


Reguläre Ausdrücke (RA) und die von ihnen beschriebenen regulären Sprachen lassen sich ebenfalls induktiv definieren:

- $\emptyset$ ist ein regulärer Ausdruck über Σ und beschreibt die reguläre Sprache $\emptyset$.
- ε ist ein regulärer Ausdruck über Σ und beschreibt die reguläre Sprache $\{\varepsilon\}$.
- a (für $a \in \Sigma$) ist ein regulärer Ausdruck über Σ und beschreibt die reguläre Sprache $\{a\}$.
- Sind r_1 und r_2 reguläre Ausdrücke, welche die regulären Sprachen R_1 bzw. R_2 beschreiben, so ist:
 - $(r_1 \mid r_2)$ ein regulärer Ausdruck und beschreibt die reguläre Sprache $R_1 \cup R_2$,
 - $(r_1 r_2)$ ein regulärer Ausdruck und beschreibt die reguläre Sprache $R_1 R_2$,
 - $(r_1)^*$ ein regulärer Ausdruck und beschreibt die reguläre Sprache R_1^* .
- Nichts sonst ist ein regulärer Ausdruck.

Übergangsdiagramme

Beispiel: regulärer Ausdruck, der Integer- und Realkonstanten ohne Vorzeichen:

$((\text{zi} (\text{zi})^*) \mid (\text{zi} (\text{zi})^* . \text{zi} (\text{zi})^* (\text{E} \text{zi} \text{zi} \mid \varepsilon)))$



Beispiel:
123.45E12

Die von dem Übergangsdiagramm akzeptierte Sprache ist die Menge der Wörter, für die es einen Weg von einem Startknoten zu einem Endknoten gibt.

Definition: Übergangsdiagramm

Ein **Übergangsdiagramm** ist ein endlicher, gerichteter, kantenmarkierter Graph

$$UD = (V, E, T, v_0, V_f), \text{ wobei}$$

- ② – V eine endliche Menge von Knoten,
- zi → – E eine endliche Menge von markierten Kanten,
- ① – $v_0 \in V$ ein ausgezeichneteter Knoten, der **Startknoten**,
- ① – und $V_f \subseteq V$ die Menge der Endknoten sind.


Die Markierung der Kanten stammt dabei aus der Menge T .

Die von dem Übergangsdiagramm akzeptierte Sprache ist

$$L(UD) = \{ w \in T^* \mid \text{es gibt einen } w\text{-Weg von } v_0 \text{ zu einem } v_f \in V_f \text{ in } UD \}$$

Nichtdeterministischer endlicher Automat (NEA)

- NEA ist ein zu Übergangsdiagrammen äquivalenter Mechanismus
- Ein **NEA** besteht aus:
 - einer **Variablen**, die nur endlich viele verschiedene Zustände annehmen kann;
 - einem **Lesekopf**, mit dem das **Eingabeband** von links nach rechts gelesen wird;
 - einer **Übergangsrelation**, die die Kontrolle des Automaten bildet;
 - einem **Anfangszustand** und
 - ein oder mehreren **Endzuständen**.



- Definition
- Rechnung

Rechnung eines NEA

Definition: NEA

- Ein **(nichtdeterministischer) endlicher Automat (NEA)** ist ein Tupel

$$M = (\Sigma, Q, \Delta, q_0, F),$$

mit

- Σ ist endliches Alphabet (das **Eingabealphabet**)
- Q ist endliche Menge von **Zuständen**
- $q_0 \in Q$ ist **Anfangszustand**
- $F \subseteq Q$ ist Menge der **Endzustände**
- $\Delta \subseteq Q \times (\square \cup \{\varepsilon\}) \times Q$ ist **Übergangsrelation**

Rechnung eines NEA

- Konfigurationen: $K = Q \times \Sigma^*$

- Rechnung:

$$(q, a.w) \rightarrow (p, w) \quad \Leftrightarrow \quad (q, a, p) \in \Delta$$


$$(q, w) \rightarrow (p, w) \quad \Leftrightarrow \quad (q, \varepsilon, p) \in \Delta$$

$\rightarrow^*$ ist die reflexive, transitive Hülle von $\rightarrow$

- Die vom NEA akzeptierte Sprache:

$$L(NEA) = \{w \mid (q_0, w) \rightarrow^* (p, \varepsilon) \text{ und } p \in F\}$$

Korrespondenz zwischen Übergangsdiagramm und NEA



NEA	Übergangsdiagramm
$q \in Q$	
q_0	
$q_f \in F$	
$(q, a, p) \in \Delta$	

Zugehöriger NEA

- Alphabet $\Sigma = \{ 0, 1, \dots, 9, ., E \}$
- Menge von Zuständen $Q = \{ z_0, z_1, \dots, z_7 \}$
- Anfangszustand $q_0 = z_0$
- Endzustände $F = \{ z_1, z_7 \}$
- Übergangsrelation $\Delta \subseteq Q \times (\Sigma \cup \{ \varepsilon \}) \times Q$:

Eingabe: 123.45E12

$(z_0, 1, z_1)$	$(z_0, 1, z_2)$	
$(z_1, 2, z_1)$	$(z_2, 2, z_2)$	
$(z_1, 3, z_1)$	$(z_2, 3, z_2)$	
kein	$(z_2, ., z_3)$	
Übergang	$(z_3, 4, z_4)$	
	$(z_4, 5, z_4)$	(z_4, ε, z_7)
	(z_4, E, z_5)	kein Übergang
	$(z_5, 1, z_6)$	(z_4, ε, z_7)
	$(z_6, 2, z_7)$	kein Übergang


	{ 0, 1, ..., 9 }	.	E	ε
z_0	{ z_1, z_2 }	$\emptyset$	$\emptyset$	$\emptyset$
z_1	{ z_1 }	$\emptyset$	$\emptyset$	$\emptyset$
z_2	{ z_2 }	{ z_3 }	$\emptyset$	$\emptyset$
z_3	{ z_4 }	$\emptyset$	$\emptyset$	$\emptyset$
z_4	{ z_4 }	$\emptyset$	{ z_5 }	{ z_7 }
z_5	{ z_6 }	$\emptyset$	$\emptyset$	$\emptyset$
z_6	{ z_7 }	$\emptyset$	$\emptyset$	$\emptyset$
z_7	$\emptyset$	$\emptyset$	$\emptyset$	$\emptyset$

RA $\rightarrow$ NEA

Satz:

Zu jedem regulären Ausdruck r gibt es einen nichtdeterministischen endlichen Automaten, der die von r beschriebene reguläre Menge akzeptiert.

Der Beweis dieses Satzes ist konstruktiv und wird durch den Algorithmus RA (reguläre Ausdrücke) nach NEA beschrieben:



Zerlege die regulären Ausdrücke an den Kanten und verfeinere das Übergangsdiagramm, bis alle Kanten mit Zeichen aus Σ oder ε markiert sind.

Eingabe: regulärer Ausdruck r über Σ


Ausgabe: Übergangsdiagramm eines NEA

Methode: Start



Algorithmus:
 $RA \rightarrow NEA$

Wende folgende Regeln so lange auf das jeweilige Ausgangsdiagramm an, bis alle Kanten mit Zeichen aus Σ oder ε markiert sind. Die Knoten in den linken Seiten der Regeln werden identifiziert mit Knoten im aktuellen Übergangsdiagramm. Alle in der rechten Seite einer Regel **neu auftretenden Knoten** entsprechen neu kreierten Knoten, also neuen Zuständen.



$$a \mid (bc)^*$$

Deterministischer endlicher Automat (DEA)

- **Definition: DEA**

Sei $M = (\Sigma, Q, \Delta, q_0, F)$ ein NEA. M heißt **deterministischer endlicher Automat (DEA)**, wenn Δ eine Funktion $\delta : Q \times \Sigma \rightarrow Q$ ist.

- **Bemerkungen:**

- Ein DEA hat keine ε -Übergänge.
- Für jedes Paar (q, a) mit $q \in Q, a \in \Sigma$ gibt es **höchstens** einen Nachfolgezustand.
- ➡ Es gibt maximal eine akzeptierende Rechnung für jedes Wort w
- ➡ Im Gegensatz zum NEA muss ein DEA nicht „raten“ und ist daher geeigneter für die lexikalische Analyse.